

MAESTRÍA EN ANALÍTICA DE DATOS

¿ATRAPALOS A TODOS?

**NO NECESITAS "ATRAPARLOS A TODOS":
REDUCCIÓN DE DIMENSIONALIDAD PARA UNA
RUN OPTIMIZADA EN POKEMON GB.**

Análisis Multivariado y Taxonomía Algorítmica de Pokémon Gen 1

Presentado por: Ana Milena Uribe, Alejandro Quintero, Francisco Mario Campo, Pablo Stevens Casilimas y Mario Bermúdez



PREGUNTA DE INVESTIGACIÓN

Hacia una eficiencia operacional basada en el espacio latente

FORMULACIÓN DEL PROBLEMA



INTERROGANTE CENTRAL

¿De qué manera la reducción de la dimensionalidad de los perfiles de resistencia elemental permite identificar redundancias funcionales para optimizar la eficiencia de un entrenador o speedrunner?



OBJETIVO DE OPTIMIZACIÓN

Minimizar el conjunto de especímenes necesarios para cubrir el máximo espectro de debilidades elementales, eliminando el sesgo de "completitud" por un paradigma de "suficiencia estratégica".



EXPLICACIÓN DEL RETO

¿Qué datos?

Dataset de Kaggle con estadísticas de 800 Pokémon (rounakbanik/pokemon). Se filtran los 151 de la Generación 1 para el análisis.

¿Qué se analiza?

18 variables de resistencia elemental (against_bug, against_fire, etc.) que describen cómo cada Pokémon enfrenta cada tipo de ataque.

¿Objetivo?

Descubrir si los Pokémon se agrupan naturalmente por sus perfiles de resistencia usando técnicas de clustering y reducción de dimensiones.

CONTEXTO: EL ESPACIO DE 18 DIMENSIONES

En la taxonomía Pokémon, cada entidad está definida por un vector ,

$$\mathbf{x} \in \mathbb{R}^{18}$$

donde cada componente representa la vulnerabilidad ante un tipo elemental específico.

- ⌚ 151 especímenes en la Generación 1.
- 🛡️ Resistencias que varían exponencialmente (0.25x a 4.0x).
- 🧠 Alta complejidad cognitiva para la toma de decisiones humana en tiempo real.



Defender \ Attacker	Normal	Fire	Water	Grass	Electric	Ice	Fighting	Poison	Ground	Flying	Psychic	Bug	Rock	Ghost	Dragon	Dark	Steel	Fairy
Normal													1/2	0			1/2	
Fire		1/2	1/2	2		2						2	1/2		1/2		2	
Water		2	1/2	1/2					2				2		1/2			
Grass		1/2	2	1/2			1/2	2	1/2			1/2	2		1/2		1/2	
Electric			2	1/2	1/2			0	2						1/2			
Ice		1/2	1/2	2		1/2			2	2					2		1/2	
Fighting	2					2		1/2		1/2	1/2	1/2	2	0		2	2	1/2
Poison				2				1/2	1/2				1/2	1/2			0	2
Ground		2		1/2	2			2		0		1/2	2				2	
Flying				2	1/2		2					2	1/2					1/2
Psychic							2	2			1/2					0	1/2	
Bug		1/2		2			1/2	1/2		1/2	2			1/2		2	1/2	1/2
Rock		2				2	1/2		1/2	2		2					1/2	
Ghost	0										2			2		1/2		
Dragon															2		1/2	0
Dark							1/2				2			2		1/2		1/2
Steel		1/2	1/2		1/2	2							2				1/2	2
Fairy		1/2					2	1/2							2	2	1/2	

LA FALACIA DE "ATRAPARLOS A TODOS"



DENSIDAD VS. EFICIENCIA

El lema tradicional sugiere que la acumulación de datos (especímenes) es proporcional al éxito. Sin embargo, en analítica avanzada:

Redundancia: Muchos Pokémon comparten el mismo vecindario en el espacio de Hilbert de resistencias.

Costo de Oportunidad: Capturar innecesariamente penaliza el tiempo (Speedrun) y el entrenamiento de recursos (Trainer).



ARQUITECTURA DEL PIPELINE ANALÍTICO



PRE-PROCESAMIENTO



Z-score Normalization &
Feature Selection.



CLUSTERING

Segmentación con
K-Means++ (k=4).



REDUCCIÓN

PCA (Lineal) y t-SNE (No
Lineal).



VALIDACIÓN

Prueba Kruskal-Wallis &
Silueta.



ESTRATEGIA

Implementación en
Batallas y Speedruns.

INGENIERÍA DE CARACTERÍSTICAS: Z-SCORE

Para garantizar que el algoritmo no se sesgara por magnitudes absolutas, aplicamos **StandardScaler**:

$$z = \frac{x - \mu}{\sigma}$$

Esto permite comparar debilidades de tipo 'Fuego' con 'Psíquico' en una escala adimensional simétrica.

```
# Normalización Multivariada
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# Selección de 18 variables elementales
cols_against = ['against_bug', 'against_dark', ...]
```



VARIABILIDAD INICIAL DEL DATASET



La disparidad en las varianzas justifica la necesidad de una reducción para identificar los ejes reales de diferenciación.



DESARROLLO METODOLÓGICO

Segmentación y Proyección del Espacio Latente


C. Selección de Algoritmo DBSCAN

Al analizar el **Diagrama** resultante del DBSCAN, el número óptimo de grupos se sitúa en **5 clústeres**.

JUSTIFICACIÓN

Epsilon: 3.8 – Determinado mediante el Método de la Rodilla (K-Distance Graph), identificando el punto donde la densidad de vecinos se dispersa.

MinPts: 5 – Definido para capturar nichos ecológicos pequeños (como los tipos Dragón o Fantasma de la Gen 1) sin perder significancia estadística, seleccionado por el método de la rodilla




A. SELECCIÓN DE GRUPOS JERÁRQUICOS

Al analizar el **Dendrograma** resultante del agrupamiento jerárquico (utilizando el método de Ward), el número óptimo de grupos se sitúa en **4 clústeres**.


JUSTIFICACIÓN

En el nivel de distancia euclidiana donde el árbol presenta el mayor salto vertical (sin cruces), se observan 4 ramas principales que corresponden a las familias elementales dominantes de la Gen 1.



B. DISTRIBUCIÓN DE GRUPOS K-MEANS

Al ejecutar K-Means con $k=4$ sobre los 151 registros de la Generación 1, la distribución poblacional es la siguiente:



Total: 151 registros analizados.

TAXONOMÍA ALGORÍTMICA: K-MEANS++

Implementamos una partición del espacio mediante **K-Means++** con $k=4$.

 **Convergencia:** Optimizada para minimizar la inercia intracluster.

 **Interpretación:** Los grupos resultantes no siguen el número de Pokédex, sino perfiles de supervivencia.

```
# Optimización de Clústeres
k_clusters = 4
kmeans = KMeans(n_clusters=k_clusters,
                 random_state=42,
                 n_init=10)
cluster_labels = kmeans.fit_predict(X_scaled)
```




MÉTRICAS DE COHESIÓN Y SEPARACIÓN

0.263


Coeficiente de Silueta

1798.0

Inercia Final



MÉTODO DE REDUCCIÓN MÁS CLARO



El método que permite una comprensión más clara es **t-SNE** (t-Distributed Stochastic Neighbor Embedding).

¿POR QUÉ T-SNE?


Mientras que PCA es una proyección lineal que puede solapar grupos, t-SNE revela "islas" no lineales. Esto permite ver visualmente grupos de Pokémon que son funcionalmente idénticos en defensa.

E. EVALUACIÓN DEL SEGUNDO GRÁFICO

¿Muestra adecuadamente la conformación?

SÍ, ABSOLUTAMENTE.

El segundo gráfico (t-SNE / Mapa Visual) muestra agrupaciones densas y separadas que coinciden con los clústeres de K-Means. A diferencia del primer gráfico (PCA), aquí la distancia visual representa fielmente el "parentesco defensivo".



T-SNE: PRESERVACIÓN TOPOLÓGICA

APROXIMACIÓN NO LINEAL

A diferencia de PCA, t-SNE utiliza una distribución T de Student para modelar distancias en el espacio de baja dimensión, permitiendo identificar "islas" de Pokémon con perfiles defensivos idénticos.



SIGNIFICADO ESTRATÉGICO

Especímenes muy cercanos en t-SNE son funcionalmente redundantes. Para un equipo eficiente, basta con elegir **uno** de cada vecindario denso.




PCA: ESTRUCTURA GLOBAL


El Análisis de Componentes Principales reveló que los dos primeros ejes explican el **35.76%** de la varianza total.

PC1: Dominado por vectores 'Flying', 'Grass' y 'Ground'.

PC2: Dominado por vectores 'Psychic', 'Bug' y 'Dark'.



CARACTERIZACIÓN DE NICHOS ECOLÓGICOS



CARACTERIZACIÓN DE NICHOS ECOLÓGICOS

AZUL

Especialistas
Acuáticos/Hielo. Alta
resiliencia a ataques
hídricos.



VERDE

Botánicos y Bípodes.
Vulnerables a fuego y
toxinas.



AMARILLO

Eléctricos y Tierra. Alta
conductividad y resistencia
sísmica.



MORADO

Místicos
(Veneno/Psíquico/Fantasma
). Perfiles de resistencia
compleja.



TENDENCIAS DE COMPONENTES PRINCIPALES

Varianza Explicada por Componente (Scree Plot Analogy)



Nota: PC1 y PC2 capturan los ejes críticos para la supervivencia en la ruta de Kanto.



VALIDACIÓN NO PARAMÉTRICA

Para corroborar la validez de los grupos, aplicamos la prueba de **Kruskal-Wallis H**:


Variable Elemental	H-Statistic	p-value	Significancia
Against Fire	142.3	< 0.001	Altamente Significativo
Against Grass	168.1	< 0.001	Altamente Significativo
Resultados Globales	--	--	17 de 18 variables


Interpretación: Rechazamos H₀. Los clústeres son poblaciones estadísticamente distintas.

CARTOGRAFÍA VISUAL DE DATOS

Al proyectar los sprites sobre las coordenadas PCA, transformamos números abstractos en una herramienta de decisión visual para el usuario final.







APLICACIONES ESTRATÉGICAS

Optimizando al Entrenador y al Speedrunner


ESTRATEGIA PARA EL ENTRENADOR

SINERGIA DE CORE Y PIVOTE

Un equipo eficiente debe evitar la redundancia inter-cluster. Si tu Pokémon líder pertenece al **Cluster Verde**, tu segundo Pokémon debe residir en el **Cluster Amarillo** o **Morado**.

 **Pivotes Defensivos:** Seleccionar especímenes de clústeres opuestos en PCA.

 **Cobertura Máxima:** Minimizar la intersección de debilidades extremas (4.0x).



CONCLUSIONES CIENTÍFICAS

- ✓ **Reducción Efectiva:** Logramos condensar 18 dimensiones en un plano 2D conservando la esencia biológica de los datos.
- 📈 **Validación Robusta:** La segmentación algorítmica es estadísticamente superior a la clasificación manual tradicional.
- ⚡ **Paradigma de Eficiencia:** "Atraparlos a todos" es una heurística obsoleta; "atrapa los puntos críticos de los clústeres" es la norma para la analítica de datos moderna.

ANÁLISIS DEL RESULTADO GRUPAL

Agrupación por tipo

Los Pokémon se agrupan principalmente según sus tipos elementales. Esto confirma que las resistencias son altamente determinadas por el tipo (ej. Pokémon de Agua comparten vulnerabilidades similares).

Validez estadística

Las 18 variables muestran diferencias significativas entre clusters (Kruskal-Wallis $p < 0.05$), lo que valida que los grupos son estadísticamente distintos y no producto del azar.

Limitaciones del modelo

Pokémon con tipo doble (ej. Charizard = Fuego/Volador) o resistencias únicas (tipo Fantasma/Veneno) pueden ubicarse en zonas de transición entre clusters.

Proyección futura

Incluir todas las generaciones, stats base (HP, Ataque, etc.) y añadir DBSCAN para detectar Pokémon legendarios como outliers naturales del dataset.

IMAGE SOURCES



https://upload.wikimedia.org/wikipedia/commons/thumb/9/97/Pokemon_Type_Chart.svg/500px-Pokemon_Type_Chart.svg.png?_=20260412142054

Source: commons.wikimedia.org



<https://preview.redd.it/presenting-pok%C3%A9mon-data-science-project-v0-06o58livrxie1.jpg?width=640&crop=smart&auto=webp&s=fc8da030b38877af2e73a927f3039b3a20b5037d>

Source: www.reddit.com